

Techniques de compilation

Auditoire : CPI-2

Année Universitaire : 2025-2026

Code Classroom: **6xqrgwgl**

Dr.-Ing. Rakia Saidi

Maitre assistante en informatique

rakia.saidi@isimg.tn

Plan de ce cours

Chapitre 1: Introduction à la compilation

Chapitre 2: Rappels à la théorie des langages

Chapitre 3: Analyse lexicale

Chapitre 4: Analyse syntaxique

Chapitre 5: Analyse sémantique

Chapitre 6: Génération de code

CHAPITRE 3: ANALYSE LEXICALE

Plan

1. Concepts de base
2. Principe de l'analyse lexicale
3. Spécification des unités lexicales

Introduction

- L'analyse lexicale constitue la première étape de la compilation.
- Le rôle de cette étape consiste à lire les caractères du texte à compiler et produire en sortie un ensemble d'unité lexicale que l'analyseur syntaxique aura traité.
- Concepts de base:
 - Unité lexicale
 - Modèle
 - Lexème

Concepts de base (1)

Définition 2.1 (Unité lexicale): Une unité lexicale est un ensemble de chaînes de caractères qui ont des significations semblables.

Exemple 2.1:

- L'unité lexicale « IDENT » regroupe tous les domaines de caractères qui représentent des identificateurs de variables, de fonctions, etc.
- L'unité lexicale OPREL regroupe les opérateurs relationnels (<, >, <>, <=, >=)

Concepts de base (2)

Définition 2.2 (Modèle): Un modèle est une règle associée à une unité lexicale qui décrit l'ensemble des chaînes de langage qui peuvent appartenir à cette unité lexicale.


Définition 2.3 (Lexème): On appelle lexème, toute chaîne de caractère du programme source qui concorde avec le modèle d'une unité lexicale.

Exemple 2.2:

- Le modèle de l'unité IDENT : « toutes les chaînes de caractères composés de chiffre, symbole, souligné « » et qui ne commence pas par un chiffre.
- i, x1, xy, _x sont des lexèmes de l'unité lexicale IDENT.

Principe d'analyse lexicale

- L'analyse lexicale se fait par l'interaction l'analyseur syntaxique:



Spécification des unités lexicales

- Les expressions régulières étudiées aux théories de langage constituent l'outil principal pour la spécification des unités lexicales.
- Pour des raisons de concision d'écriture, on se permet des symboles supplémentaires:
 - Le symbole « - » sera utilisé pour définir une séquence ordonnée de symboles.
 - L'opérateur d'union « U » sera désigné par le symbole « | ».
- **Exemple 2.1**: la notation « a-z|A-Z » désigne les lettres minuscules et majuscules.

Spécification des unités lexicales

Définition 1.4: Une définition régulière est une suite de définition de la forme :

$$\begin{cases} d_1 = r_1 \\ d_2 = r_2 \\ \dots \\ d_n = r_n \end{cases}$$

Où :

- d_i désigne l'identificateur de la définition régulière.
- r_i désigne est une expression régulière sur l'alphabet $\Sigma \cup \{d_1, d_2, \dots, d_{n-1}\}$.

Spécification des unités lexicales

- **Exemple 2.2:** la définition régulière pour l'unité lexicale IDENT du langage C :

$$\left\{ \begin{array}{l} \text{lettre} = A-Z \mid a-z \\ \text{chiffre} = 0-9 \\ \text{sep} = \text{« } _ \text{»} \\ \text{ident} = (\text{lettre} \mid \text{sep})(\text{lettre} \mid \text{chiffre} \mid \text{sep})^* \end{array} \right.$$

- Exercice: proposez un automate fini qui reconnaît les chaînes qui correspondent à des identificateurs valides de variables.

Attributs des unités lexicales

- Quand plus d'un modèle reconnaît un lexème, l'analyseur lexical doit fournir aux phases suivantes du compilateur des informations additionnelles sur le lexème reconnu.
- ➔ Ces informations sont appelées **attributs des unités lexicales**.
- **Exemple 2.3**: le modèle nb (nombre) correspond à la fois aux chaînes 0 et 1, mais il est essentiel pour le générateur de code de savoir quelle chaîne a effectivement été reconnue.

Attributs des unités lexicales

- L'analyseur lexical réunit les informations sur les unités lexicales dans les attributs qui leur sont associés.
 - Les unités lexicales influent sur les décisions d'analyse syntaxique.
 - Les attributs influent sur la traduction des unités lexicales.
- Une unité lexicale dispose d'un seul attribut :
 - Un pointeur vers l'entrée de la table de symboles dans laquelle l'information sur l'unité lexicale est conservée.
 - Le pointeur devient l'attribut de l'unité lexicale.

Remarques

- L'analyse lexicale effectue d'autres tâches secondaires qui sont entre autres :
 - Élimination des commentaires et des espaces (blanc, retour à la ligne, tabulation...)
 - Liaison des messages d'erreurs issus de la compilation au programme source (gérer les numéros de ligne);

Exercice

- On considère un langage des instructions dont la définition est la suivante:
 - $\text{instr} \rightarrow \text{if expr then istr} \mid \text{if expr then instr else instr} \mid \epsilon$
 - $\text{expr} \rightarrow \text{term oprel term} \mid \text{term}$
 - $\text{term} \rightarrow \text{id} \mid \text{nb}$
- Où le symbole id (resp. nb) désigne un identificateur de variables (resp. des nombres).

Questions:

- Proposez une définition régulière aux éléments suivants: oprel et term.
- Donnez les unités lexicales et leurs attributs.

Solution d'exercice

- Définition régulière:

$$\left\{ \begin{array}{l} l = A-Z \mid a-z \\ c = 0-9 \\ s = \text{« } _ \text{»} \\ oprel = < \mid <= \mid = \mid <> \mid > \mid \geq \\ id = (l \mid s)(l \mid c \mid s)^* \\ nb = c^+ (. c^+ \mid \epsilon)(E (+ \mid - \mid \epsilon) c^+ \mid \epsilon) \end{array} \right.$$

Solution d'exercice

- Unités lexicales et valeurs d'attributs :

Expression régulière	Unité lexicale	Valeur d'attribut
if	if	-----
then	then	-----
else	else	-----
id	id	Pointeur vers une entrée de la table de symboles
nb	nb	Pointeur vers une entrée de la table de symboles
<	oprel	PPQ
<=	oprel	PPE
>	oprel	PGQ
>=	oprel	PGE
<>	DIFF	DIFF
=	EQA	EGA